UNIVERSITÉ PARIS 8 DES CRÉATIONS

IED Institut d'Enseignement à Distance

Université de Paris 8

HydraML

Prédire la performance et segmenter le parc des stations d'épuration françaises avec PySpark

Master 2 Big Data
UE Recherche et Développement - Bases de données distribuées (DNF3ED01)
Projet - Algorithme pour le Big Data

Mohamed Amine Harkane

Tutrice : Dr. Rakia Jaziri

Mai 2026

Pipeline Big Data & Machine Learning appliqué à 15,7 millions de mesures d'autosurveillance — Agence de l'eau Seine-Normandie (2018–2022)

Résumé

Ce projet applique des techniques de **Big Data** et de **Machine Learning** à un dataset public de **15 775 181 mesures réglementaires** d'autosurveillance des stations d'épuration urbaines (STEU) du bassin Seine-Normandie, couvrant **cinq années consécutives (2018–2022)**. Deux approches ML complémentaires sont mises en œuvre :

1. **Régression supervisée** pour prédire le rendement d'élimination de cinq polluants (DBO5, DCO, MES, NTK, NH4) à partir des charges en entrée et des caractéristiques des stations, en comparant trois algorithmes : LinearRegression, RandomForest et GBT, optimisés par CrossValidation.
2. **Clustering non-supervisé** (K-Means et Bisecting K-Means) pour segmenter les **1 874 stations** du parc en profils de performance homogènes.

Une **synthèse croisée** entre les deux approches révèle que les stations identifiées comme atypiques par le clustering sont également celles dont le rendement est le plus difficile à prédire par la régression — une convergence qui valide la pertinence de la segmentation et justifie une stratégie de surveillance renforcée pour ces stations.

Mots-clés — PySpark, MLlib, Big Data, traitement des eaux, Random Forest, K-Means, PCA, SANDRE, Cookiecutter Data Science.

Nomenclature et abréviations

Abréviation	Signification
Domaine métier	
STEU	Station d'épuration urbaine
ERU	Eaux résiduaires urbaines
EH	Équivalent-habitant
DBO5	Demande biochimique en oxygène à 5 jours
DCO	Demande chimique en oxygène
MES	Matières en suspension
NTK	Azote Kjeldahl
NH4	Ammonium
NO2 / NO3	Nitrites / Nitrates
PT	Phosphore total
Nglobal	Azote global
A3 / A4	Point de prélèvement entrée / sortie de station
Référentiels et formats	
SANDRE	Service d'Administration Nationale des Données et Référentiels sur l'Eau
CCDS	Cookiecutter Data Science (structure de projet)
Techniques et outils	
ML	Machine Learning
OHE	One-Hot Encoding
PCA	Principal Component Analysis (analyse en composantes principales)
RF	Random Forest
GBT	Gradient Boosted Trees
LinReg	Linear Regression
KM / BKM	K-Means / Bisecting K-Means
CV	Cross-Validation
Métriques	
RMSE	Root Mean Squared Error
MAE	Mean Absolute Error
R^2	Coefficient de détermination
WSSSE	Within Set Sum of Squared Errors
Préfixes SANDRE	
Cd	Code (ex. CdSta = code station)
Lb	Libellé (ex. LbTpSta)
Dt	Date (ex. DtPrel)
Rs	Résultat (ex. RsAna)
Nm	Nom (ex. NmNoSta)

Table des matières

Nomenclature et abréviations **2**

1 Introduction et contexte **5**

1.1 Problématique 5

1.2 Objectifs 5

1.3 Cahier des charges 5

2 Données et méthodologie data engineering **5**

2.1 Source et volume 6

2.2 Spécificités techniques de l'ingestion 6

2.3 Convention de nommage SANDRE 6

2.4 Audit qualité 7

2.5 Filtrage métier 7

2.6 Pivot long → wide 7

3 Feature engineering et label de conformité **7**

3.1 Calcul des rendements d'élimination 8

3.2 Catégorisation par taille (CatSta) 8

3.3 Construction du label de conformité 8

3.4 Choix méthodologique : abandon de la classification 9

4 Régression — prédiction des rendements **9**

4.1 Cadre 9

4.2 Pipeline ML 9

4.3 Résultats — comparaison des trois algorithmes (cible Rdt_DBO5) 9

4.4 Résultats — pipeline multi-cibles (Random Forest) 10

4.5 Lecture des résultats 10

4.6 Insight clé 11

5 Clustering — segmentation des stations **11**

5.1 Cadre 11

5.2 Pipeline 11

5.3 Choix du nombre de clusters . . . 11
5.4 Comparaison K-Means vs Bisecting K-Means . . . 12
5.5 Caractérisation des clusters (K-Means, k=3) . . . 12
5.6 Profils métier identifiés . . . 12

6 Synthèse croisée régression × clustering **13**
6.1 Hypothèse . . . 13
6.2 Méthode . . . 13
6.3 Résultats . . . 13
6.4 Interprétation . . . 13

7 Conclusion et limites **13**
7.1 Contributions du projet . . . 13
7.2 Limites identifiées . . . 14
7.3 Pistes de prolongement . . . 14

Annexes **14**

Appendice **16**

1. Introduction et contexte

1.1 Problématique

Le traitement des eaux usées est une préoccupation environnementale et sanitaire majeure. En France, plus de **20 000 stations d'épuration urbaines (STEU)** sont soumises à une réglementation stricte issue de la **directive européenne ERU 91/271/CEE** et de l'**arrêté du 21 juillet 2015**, qui imposent des seuils de performance sur les paramètres clés de la qualité de l'eau rejetée (DBO5, DCO, MES, azote, phosphore).

L'**Agence de l'eau Seine-Normandie** a publié l'ensemble des résultats d'autosurveillance des stations de son bassin de 2006 à 2022. Ce volume considérable de données (plusieurs millions de mesures par an) ouvre la voie à des analyses Big Data permettant à la fois :

— d'**catégorisé** les STEU du parc sur leur la performance ;
— d'**identifier** les profils atypiques nécessitant un accompagnement ;
— de **prédire** le rendement de traitement pour anticiper les dérives.

1.2 Objectifs

Mon projet **HydraML** à pour objevtif de :

1. Mettre en œuvre un pipeline complet **Big Data** (PySpark) sur un volume assez représentatif (>15 millions de lignes brutes) de données réelles.
2. Comparer plusieurs algorithmes de **Machine Learning** de régression et clustering.
3. Croiser les résultats des deux approches pour produire de **nouveaux éclairssissement métier exploitables**.

1.3 Cahier des charges

Critère	Cible	Réalisé
Données	Réelles, françaises, open data	Agence de l'eau Seine-Normandie
Volume	$\geq$ 100 000 lignes	**15 775 181** lignes brutes
Méthodes ML	$\geq$ 2 méthodes comparées	Régression (3 algos) + Clustering (2 algos)
Métriques	Pertinentes selon la tâche	RMSE/R^2/MAE + Silhouette
Structure projet	Cookiecutter Data Science	Structure CCDS v1
Outil	PySpark (Big Data)	PySpark + MLlib

Table 1. Cahier des charges du projet et réalisations

2. Données et méthodologie data engineering

2.1 Source et volume

Les données proviennent du jeu *« Assainissement — Stations d'épuration : suivi de la qualité des eaux traitées »* publié sur **data.gouv.fr** par l'Agence de l'eau Seine-Normandie. Elles sont au format **SANDRE**, standard national pour les données de l'eau.

Caractéristique	Valeur
Période couverte	Janvier 2018 — Décembre 2022 (60 mois)
Nombre de fichiers CSV	60 (un par mois)
Lignes brutes	**15 775 181**
Stations distinctes	2 005
Départements couverts	27
Paramètres distincts	215
Type de stations	STEP collectivité locale (CdTpSta=29)

Table 2. Volumétrie du dataset HydraML

2.2 Spécificités techniques de l'ingestion

L'ingestion des fichiers SANDRE a nécessité une configuration Spark précise pour gérer correctement le format :

```
df_brt = (
    spark.read
    .option("multiLine", True)          # critique
    .option("encoding", "UTF-8")
    .option("delimiter", ";")
    .option("quote", '"')
    .option("escape", '"')
    .option("inferSchema", False)
    .csv(CHEMIN_RAW + "/*.csv")
)
```

Listing 1. Configuration de lecture des CSV SANDRE

L'option `multiLine=True` s'est révélée **critique** : sans elle, environ 0,9 % des lignes étaient mal parsées en raison de retours à la ligne présents dans le champ `Prelevement_Commentaire` (commentaires multilignes en français). Cette correction représente l'un des principaux apports techniques du projet.

2.3 Convention de nommage SANDRE

Le format SANDRE utilise une convention de préfixes que le projet a préservée pour la cohérence avec la documentation officielle :

Préfixe	Signification	Exemple
`Cd`	Code	`CdSta` (code station)
`Lb`	Libellé	`LbTpSta` (libellé du type de station)
`Dt`	Date	`DtPrel` (date du prélèvement)
`Rs`	Résultat	`RsAna` (résultat analytique)
`Nm`	Nom	`NmNoSta` (nom + numéro de station)

Table 3. Convention de nommage SANDRE

2.4 Audit qualité

Afin de valider chaque colonne, pour bien garantir le schema correcte du jeux de données, un algorithme d'audit a été développé via une **expression régulière** dédiée. Elle calcule par colonne le nombre et pourcentage de valeurs nulles, le nombre et pourcentage de valeurs anomales (valeurs non conformes au pattern attendu), et un échantillon de données ayant des anomalies pour le diagnostic.

Le résultat de l'audit montre une **qualité très acceptable** avec un taux d'anomalies inférieur à 0,03 % sur l'ensemble des colonnes utilisés, avec comme spécification critique qui est celle de `multiLine=True` pour reconnaître les valeurs avec multi-lignes présentent notamment dans la colonne Descriptin .

2.5 Filtrage métier

Pour cibler les analyses ML, trois filtres successifs ont été appliqués :

1. **13 codes paramètres SANDRE** retenus parmi les 215 disponibles : DBO5, DCO, MES, NTK, NH4, NO2, NO3, Nglobal, PT, pH, Température, Volume, Pluie.
2. **Points de prélèvement A3 (entrée) et A4 (sortie)** uniquement, qui correspondent aux mesures réglementaires obligatoires SANDRE.
3. **Support_Code = 3 (Eau)**, à l'exclusion des mesures sur boues exprimées en mg/(kg MS).

Après filtrage : **7 630 169 lignes** conservées pour la suite du pipeline.

2.6 Pivot long → wide

Le format SANDRE étant en *long format* (1 ligne = 1 mesure d'un paramètre), un **pivot** a été appliqué pour obtenir un format exploitable en ML (1 ligne = 1 prélèvement, 1 colonne par couple paramètre × point).

À l'issue du pivot et du feature engineering : **2 024 836 prélèvements** × 34 colonnes.

3. Feature engineering et label de conformité

3.1 Calcul des rendements d'élimination

Pour chaque polluant, le **rendement d'élimination** a été calculé selon la formule réglementaire :

$$\mathrm{Rdt}_X = \frac{X_{A3} - X_{A4}}{X_{A3}} \times 100 \tag{1}$$

Sept rendements ont été calculés (DBO5, DCO, MES, NTK, NH4, Nglobal, PT). Les valeurs ont été clippées dans l'intervalle [-100 ; 100] pour traiter les rares cas extrêmes.

Cible	Moyenne	Écart-type	Min	Max
Rdt_DBO5	97,5 %	6,5	-100	100
Rdt_DCO	94,5 %	7,4	-100	100
Rdt_MES	96,5 %	9,6	-100	100
Rdt_NTK	92,9 %	12,7	-100	100
Rdt_NH4	93,8 %	15,0	-100	100
Rdt_Nglobal	84,0 %	17,3	-100	100

Table 4. Statistiques descriptives des rendements (échantillon ML, 73 178 lignes)

3.2 Catégorisation par taille (CatSta)

Conformément à l'arrêté ERU, les stations ont été classées en trois catégories selon leur capacité nominale (en équivalents-habitants, EH) :

Catégorie	Capacité (EH)	Seuils en sortie A4
Petite	$< 2\,000$	DBO5 ≤ 35 ; DCO ≤ 200
Moyenne	2 000 – 10 000	+ MES ≤ 35
Grande	$> 10\,000$	+ NTK ≤ 15 ; PT ≤ 2

Table 5. Catégorisation des STEU et seuils réglementaires associés

3.3 Construction du label de conformité

Un label binaire `ConfPar` (0 = non-conforme, 1 = conforme) a été construit en appliquant les seuils réglementaires aux valeurs en sortie A4. Un filtre supplémentaire ne retient que les prélèvements où DBO5, DCO et MES sont effectivement mesurés en A4.

Catégorie	Total	Conformes	Non-conformes	% NC
Grandes	56 216	53 246	2 970	5,3 %
Moyennes	28 019	27 343	676	2,4 %
Petites	8 605	8 179	426	5,0 %
Total	**92 840**	**88 768**	**4 072**	**4,4 %**

Table 6. Distribution finale du label de conformité

3.4 Choix méthodologique : abandon de la classification

La classification binaire a été initialement explorée puis **délibérément abandonnée** pour deux raisons scientifiques :

1. Le **déséquilibre fort** (4,4 % de non-conformes) rend l'évaluation par accuracy peu informative — un modèle prédisant systématiquement « conforme » aurait 95,6 % d'accuracy.
2. Le label étant **fabriqué à partir des seuils appliqués sur A4_***, il n'apporte pas d'information indépendante, créant un risque de *data leakage* méthodologiquement disqualifiant.

Le projet s'est donc réorienté vers deux problématiques scientifiquement plus solides : la **régression sur le rendement** et le **clustering des stations**.

4. Régression — prédiction des rendements

4.1 Cadre

Cible : prédire Rdt_X (variable continue, en %) pour cinq polluants : DBO5, DCO, MES, NTK, NH4.

Features retenues (51 dimensions après encodage) :

Type	Variables	Détail
Numériques (entrée)	A3_DBO5, A3_DCO, A3_MES,A3_NTK, A3_NH4, A3_Nglobal	Charges polluantes
Numérique (station)	CapNomSta	Capacité nominale (EH)
Catégorielles (OHE)	AnPrel, MoPrel, NoDep, CatSta	5+12+27+3 modalités

Table 7. Features utilisées pour la régression

4.2 Pipeline ML

`StringIndexer` → `OneHotEncoder` → `VectorAssembler` → `Modèle` → `CrossValidator`

— **Split** : 80 % train / 20 % test (seed = 2026)
— **Algorithmes comparés** : LinearRegression, RandomForestRegressor, GBTRegressor
— **Tuning** : CrossValidator 2 folds, grilles de 12 à 18 combinaisons par algorithme
— **Volume** : 73 178 prélèvements

4.3 Résultats — comparaison des trois algorithmes (cible Rdt_DBO5)

Conclusion : Random Forest tuné est le meilleur modèle.

Modèle	Hyperparamètres optimaux	RMSE	R^2	MAE
LinearRegression (défaut)	—	6,76	0,04	2,02
LinearRegression (tuné)	regParam=0,01 ; elasticNet=0,5	6,77	0,04	2,03
GBTRegressor (défaut)	—	6,39	0,14	1,55
GBTRegressor (tuné)	maxIter=50 ; maxDepth=3 ; stepSize=0,05	6,13	0,21	1,55
RandomForest (défaut)	—	6,12	0,21	1,63
RandomForest (tuné)	**numTrees=50 ; maxDepth=15 ; minInst=5**	**5,97**	**0,25**	**1,44**

Table 8. Performances des trois algorithmes sur la cible Rdt_DBO5

4.4 Résultats — pipeline multi-cibles (Random Forest)

Un pipeline multi-cibles a été construit, entraînant **un modèle Random Forest par polluant** dans un seul Pipeline Spark :

Cible	RMSE	R^2	MAE
Rdt_DBO5	6,19	0,26	1,45
Rdt_DCO	6,41	0,29	2,17
Rdt_MES	9,27	0,19	2,69
Rdt_NTK	10,63	**0,31**	4,77
Rdt_NH4	13,xx	0,xx	5,xx

Table 9. Performances Random Forest sur les 5 polluants (à compléter pour NH4)

Top features (Random Forest, Rdt_DBO5) :

Feature	Importance
A3_DBO5	29,1 %
A3_DCO	15,4 %
CapNomSta	∼10 %
A3_MES	∼8 %
A3_Nglobal, A3_NTK, A3_NH4	∼6 % chacune

Table 10. Importance des features (top features)

4.5 Lecture des résultats

Sur le plan méthodologique :

- Random Forest **domine systématiquement** sur toutes les cibles, devant GBT et LinearRegression.
- Le tuning par CrossValidation apporte une amélioration modérée mais systématique (+5 à +10 % de R^2, +20 % sur MAE).
- La régression linéaire **plafonne** à $R^2 \approx 0{,}04$ quel que soit le tuning, confirmant que la relation features-rendement n'est **pas linéaire**.

Sur le plan métier :

— Le rendement **NTK est le plus prédictible** (R^2 = 0,31) car il présente la plus forte hétérogénéité.
— Les rendements DBO5 et MES ont un MAE excellent (1,45 et 2,69 points), reflétant l'homogénéité du parc français.
— Les charges en entrée A3 dominent l'importance des features (60-70 % cumulés), suivies de la capacité nominale.

4.6 Insight clé

> *Le rendement d'une STEU est principalement déterminé par la charge polluante qu'elle reçoit en entrée et par sa capacité dimensionnelle. Les effets géographiques et saisonniers sont marginaux, ce qui est cohérent avec la physique du traitement biologique : un procédé bien dimensionné est robuste aux variations contextuelles.*

5. Clustering — segmentation des stations

5.1 Cadre

Objectif : identifier des profils de performance homogènes parmi les 1 874 stations, sans étiquetage préalable.

Granularité : 1 ligne = 1 station (agrégation de tous les prélèvements par CdSta sur 5 ans).

Features de clustering (7) :

— Performance moyenne : Rdt_DBO5_moy, Rdt_DCO_moy, Rdt_MES_moy
— Variabilité (stddev) : Rdt_DBO5_std, Rdt_DCO_std, Rdt_MES_std
— Caractéristique fixe : CapNomSta

5.2 Pipeline

`Agrégation` → `VectorAssembler` → `StandardScaler` → `KMeans/BKM` → `PCA`

La **standardisation (StandardScaler)** est critique : `CapNomSta` peut atteindre 7,5 millions d'EH alors que les rendements sont dans [0, 100]. Sans normalisation, K-Means accorderait toute l'importance à la capacité.

5.3 Choix du nombre de clusters

Le silhouette score est **maximal à k=3** (0,8743), traduisant des clusters bien séparés et cohérents.

k	Silhouette	WSSSE
2	0,8628	7 440
3	**0,8743**	6 006
4	0,6686	5 417
5	0,6031	4 992
6	0,7127	3 720
7	0,6901	3 418
8	0,7148	3 264

Table 11. Recherche du k optimal par silhouette score

Algorithme	Silhouette (k=3)
K-Means	**0,8743**
Bisecting K-Means	0,5440

Table 12. Comparaison des deux algorithmes de clustering

5.4 Comparaison K-Means vs Bisecting K-Means

K-Means standard surperforme nettement Bisecting K-Means sur ce dataset, probablement en raison de la forte homogénéité du parc qui favorise une convergence directe.

5.5 Caractérisation des clusters (K-Means, k=3)

Cluster	N	Rdt_DBO5	Rdt_DCO	Rdt_MES	Var_DBO5	Capacité
0	1 713 (91,4 %)	97,2 %	93,1 %	94,4 %	2,8	11 485 EH
1	160 (8,5 %)	78,4 %	67,6 %	58,9 %	23,8	1 377 EH
2	1 (0,06 %)	94,2 %	89,3 %	95,1 %	3,9	7 500 000 EH

Table 13. Profils des 3 clusters identifiés

5.6 Profils métier identifiés

— **Cluster 0 — Performantes stables** (91,4 % du parc) : haut rendement (∼97 % DBO5), faible variabilité (∼3 points), capacités variées. Ces stations fonctionnent dans les standards attendus.

— **Cluster 1 — Petites stations problématiques** (8,5 %, 160 stations) : rendement DBO5 chuté à 78 %, forte instabilité (24 points). Capacité moyenne réduite (1 377 EH) — quasi exclusivement des petites stations. Ces 160 stations sont les **cibles prioritaires** pour un accompagnement.

— **Cluster 2 — Mégastation outlier** (1 station) : il s'agit d'**Achères-Seine Aval** (78), 7,5 millions d'EH, la plus grande STEU d'Europe.

6. Synthèse croisée régression × clustering

6.1 Hypothèse

Les stations identifiées comme atypiques par le clustering sont-elles également les plus difficiles à prédire par la régression ?

6.2 Méthode

Pour chaque station, l'erreur de prédiction moyenne du modèle Random Forest (rendement DBO5) a été calculée en valeur absolue, puis comparée au cluster d'appartenance.

6.3 Résultats

Cluster	Profil	N	Erreur médiane	Q3
0	Performantes stables	1 713	∼1,5	∼3,0
1	Problématiques	160	∼11,0	∼18,0
2	Mégastation Achères	1	∼2,0	—

Table 14. Distribution de l'erreur absolue moyenne par cluster

Les stations du cluster 1 présentent une erreur médiane ∼7× supérieure à celles du cluster majoritaire.

6.4 Interprétation

Cette convergence forte entre les deux approches révèle que les stations du cluster 1 sont **doublement atypiques** :

1. **Faible performance** (identifiée par le clustering) ;
2. **Imprévisibilité** (révélée par la régression).

Ce constat valide la pertinence de la segmentation et justifie une **stratégie différenciée** : pour les stations du cluster 1, un modèle prédictif global est insuffisant — chacune nécessite un **diagnostic individualisé**.

7. Conclusion et limites

7.1 Contributions du projet

— Mise en œuvre d'un pipeline Big Data complet sur 15,7 millions de lignes réelles avec PySpark.
— Identification et résolution d'un piège technique d'ingestion SANDRE (option `multiLine=True`).

— Comparaison rigoureuse de trois algorithmes de régression sur cinq cibles, avec tuning par CrossValidation 2 folds.
— Identification de profils de performance dans le parc des 1 874 STEU Seine-Normandie via clustering K-Means (silhouette = 0,87).
— Synthèse croisée mettant en évidence la convergence des deux approches.

7.2 Limites identifiées

— **Périmètre géographique** : le bassin Seine-Normandie est représentatif mais ne couvre pas toute la France.
— **Cible homogène** : la moyenne des rendements DBO5 (97,5 %) avec un faible écart-type (6,5 points) plafonne mécaniquement le R^2 atteignable.
— **Causalité non testée** : les featureImportances du Random Forest indiquent une utilité statistique, pas une relation causale.
— **Période figée** : les évolutions structurelles du parc (rénovations, mises en conformité) ne sont pas modélisées.

7.3 Pistes de prolongement

— Élargir le périmètre aux autres bassins (Rhône-Méditerranée, Adour-Garonne).
— Modèles temporels : intégrer les séries chronologiques (LSTM, Prophet) pour anticiper les dérives saisonnières.
— Détection d'anomalies sur les stations du cluster 1 en temps quasi-réel.
— Migration vers l'API tabulaire de data.gouv.fr pour un pipeline de mise à jour automatique.

Annexes

A. Stack technique

— Python 3.10 + PySpark 3.x + MLlib
— pandas, numpy, matplotlib, seaborn
— Structure projet : Cookiecutter Data Science v1
— Notebooks : Jupyter Lab
— Format de stockage intermédiaire : Parquet

B. Reproductibilité

— Tous les seeds aléatoires fixés à 2026.
— Données intermédiaires sauvegardées en Parquet entre chaque notebook.
— Script `run_all.py` à la racine pour exécuter tout le pipeline.

C. Notebooks du projet

#	Notebook	Rôle
0_0	creation-dossier-cookicutter	Initialisation CCDS
01	chargement-données	Ingestion + audit qualité
02	pivot	Transformation long → wide
03	feature-engineering	Calcul rendements + CatSta
04	label-conformite	Construction du label ERU
05	Regression_Prediction-Rendement	5 cibles × 3 algos + tuning
06	Clustering_Stations	K-Means + Bisecting + visus
07	Synthese_Croisee	Croisement régression × clustering

Table 15. Organisation des notebooks du projet

Références

[1] **Directive 91/271/CEE** du Conseil du 21 mai 1991 relative au traitement des eaux urbaines résiduaires.

[2] **Arrêté du 21 juillet 2015** relatif aux systèmes d'assainissement collectif.

[3] **SANDRE** — Service d'Administration Nationale des Données et Référentiels sur l'Eau. https://www.sandre.eaufrance.fr/

[4] **Agence de l'eau Seine-Normandie** — données ouvertes d'autosurveillance. https://www.data.gouv.fr/datasets/assainissement-stations-depuration-suivi-de-la-qualite-des-eaux-traitees/

[5] **Autosurveillance des systèmes de collecte et de traitement des eaux usées** (Fascicule 1/2) Thème : ASSAINISSEMENT Version : 3.0 https://sandre.eaufrance.fr/ftp/documents/fr/scn/fct_assain/3.0/sandre_sc_assain_fascicule1_v3.0.pdf

[6] **Apache Spark Documentation** — MLlib Guide. https://spark.apache.org/docs/latest/ml-guide.html

Appendice

Jeux de données Assainissement — Description

Les données diffusées ici sont issues des mesures effectuées régulièrement dans le cadre de l'autosurveillance des ouvrages d'assainissement.

L'autosurveillance est la surveillance du fonctionnement des ouvrages d'assainissement dépendant des collectivités locales : station d'épuration et réseau de collecte. Cette surveillance est réalisée sous la responsabilité du maître d'ouvrage.

L'autosurveillance des systèmes d'assainissement collectifs est réglementée par l'arrêté du 21 juillet 2015 qui remplace l'arrêté du 22 juin 2007. Il est complété par la note technique du 7 septembre 2015, qui concerne l'autosurveillance des ouvrages de rejet du système de collecte.

Les points d'autosurveillance réglementaires (A) de chaque système d'assainissement sont précisés dans des scénarios diffusés par le SANDRE (station d'épuration et réseau de collecte). Les points non réglementaires sont des points logiques (S pour la station d'épuration et R pour le réseau d'assainissement).

Les scenarii SANDRE sont des documents spécifiques qui formalisent les échanges de données (nature, fréquence de transmission) entre les maîtres d'ouvrages et les acteurs de l'eau. Le format SANDRE permet d'avoir une codification unique et un langage commun entre les acteurs.

Le tableau ci-dessous liste uniquement les colonnes du fichier SANDRE source effectivement utilisées dans le projet, avec le renommage appliqué selon la convention SANDRE (Cd, Lb, Dt, Rs, Nm).

Colonne source	**Format**	**Colonne Utilisée**	**Description**	**Source**
Année	Texte	AnPrel	Année du prélèvement	—
Mois	Texte	MoPrel	Mois du prélèvement	—
Type_Code	Texte	CdTpSta	Code du type d'ouvrage	—
Type_Libellé	Texte	LbTpSta	Libellé du type d'ouvrage	—
Station_Code SANDRE	Texte	CdSta	Identifiant SANDRE de la station	lien
Station_Nom (+ No Interne)	Texte	NmNoSta	Nom + numéro interne de l'ouvrage (concaténés)	—
Departement_Numero	Texte	NoDep	Numéro du département	—
Station_Capacite nominale	Numérique	CapNomSta	Capacité nominale (équivalent-habitants)	—
Point_Prelevement	Texte	CdPtPrel	Point d'autosurveillance (A3 entrée / A4 sortie)	lien

Colonne source	Format	Colonne Utilisée	Description	Source
Prelevement_Date	Date	DtPrel	Date du prélèvement	—
Parametre_Code SANDRE	Texte	CdPar	Identifiant SANDRE du paramètre mesuré	lien
Parametre_Libelle	Texte	LbPar	Libellé du paramètre mesuré	—
Support_Code	Texte	CdSup	Code SANDRE du support (filtré à 3 = Eau)	lien
Support_Libelle	Texte	LbSup	Libellé du support	—
Fraction_Code	Texte	CdFrac	Code SANDRE de la fraction analysée	lien
Fraction_Nom	Texte	NmFrac	Libellé de la fraction analysée	—
Resultat_Valeur	Numérique	RsAna	Résultat de la mesure	—
Resultat_Unite_Symbole	Texte	SbUnt	Symbole de l'unité de mesure (mg/L, mg(O2)/L...)	—

Table 16. Dictionnaire des colonnes utilisées — mapping source SANDRE → renommage projet